



Ce que « une fenêtre de k phrases » pèse vraiment



Médiane et interquartile



Lentille val. À gauche, la distribution des longueurs pour chaque taille de fenêtre (aire normalisée, trait = médiane). À droite, la même chose résumée.

Le point : sur les jeux held-out, un « document entier » fait 70 tokens de médiane et une fenêtre de 6 phrases en fait 181 — le document est PLUS COURT. Ordonner les régimes par nombre de phrases et les ordonner par longueur réelle ne donnent donc pas le même ordre, et c'est la longueur réelle que le modèle encode. D'où l'axe en tokens partout ailleurs.